## Rapport de Projet de Fin de Module

# Classification Automatique de Contenus Textuels Domaine Médical vs Domaine Général

**Réalisé par :**

El Hafi Anass

El Hadi Hassan

Gasmi Zakaria

Benhmidya Ayoub

**Encadré par :**

Prof. Ichrak BENAMRI

Année universitaire : 2024–2025

# Résumé

Ce projet vise à concevoir un système intelligent capable de classifier automatiquement des textes en deux catégories : articles médicaux et articles non médicaux. En s'appuyant sur les techniques du Traitement Automatique du Langage Naturel (NLP) et du Machine Learning, un pipeline complet a été mis en place incluant la collecte des données, leur prétraitement, l'analyse exploratoire, l'entraînement de modèles de classification et leur déploiement dans une application temps réel. Les résultats obtenus montrent que le modèle de Régression Logistique atteint une précision de 98,46%, démontrant l'efficacité de l'approche adoptée.

# Table des matières

**Résumé** **1**

**Introduction Générale** **4**

**1 Cahier de charges et déroulement du projet** **5**
1.1 Compréhension du projet . . . . . 5
1.2 Objectifs et contraintes . . . . . 5
1.3 Déroulement du projet . . . . . 5

**2 Étude bibliographique** **6**
2.1 Traitement Automatique du Langage Naturel . . . . . 6
2.2 Vectorisation TF-IDF . . . . . 6
2.3 Algorithmes de classification . . . . . 6

**3 Vue conceptuelle** **7**
3.1 Collecte des données . . . . . 7
3.2 Prétraitement des données . . . . . 7
3.3 Analyse de la distribution des classes . . . . . 7

**4 Implémentation et résultats** **8**
4.1 Analyse exploratoire des données . . . . . 8
4.1.1 Distribution des longueurs des textes . . . . . 8
4.1.2 Analyse comparative par boxplot . . . . . 9
4.1.3 Analyse lexicale et nuages de mots . . . . . 9
4.1.4 Analyse des mots les plus fréquents . . . . . 10
4.1.5 Longueur moyenne des textes par classe . . . . . 11
4.1.6 Distribution des classes . . . . . 11
4.2 Modélisation et résultats . . . . . 12
4.2.1 Résultats de la Régression Logistique . . . . . 12
4.2.2 Résultats du Random Forest . . . . . 13
4.2.3 Comparaison des modèles . . . . . 13
4.3 Application en temps réel . . . . . 13

**Conclusion générale et perspectives** **15**

# Introduction Générale

Avec l'explosion des contenus textuels disponibles sur Internet, la classification automatique des documents est devenue une problématique centrale en intelligence artificielle. Dans le domaine médical, il est essentiel de distinguer les publications scientifiques fiables des articles généralistes. Ce projet s'inscrit dans cette optique et propose une solution basée sur l'analyse automatique du texte afin de faciliter le filtrage et l'accès à l'information pertinente.

L'objectif principal est de développer un système capable de comprendre le contenu sémantique d'un texte et de déterminer automatiquement son domaine d'appartenance. Pour atteindre cet objectif, plusieurs étapes méthodologiques ont été suivies, allant de la compréhension du problème jusqu'au déploiement d'une application interactive.

# Chapitre 1 Cahier de charges et déroulement du projet

## 1.1 Compréhension du projet

Le projet consiste en une tâche de classification binaire visant à déterminer si un texte appartient au domaine médical ou au domaine général. Le système doit être capable de traiter des textes de longueurs variables, d'identifier les mots clés pertinents et de produire une prédiction fiable en un temps réduit.

## 1.2 Objectifs et contraintes

Les objectifs principaux sont :

- Assurer une précision élevée de classification.
- Réduire les erreurs de confusion entre les deux domaines.
- Offrir une interface simple et accessible.

Les contraintes concernent principalement la qualité des données, la similarité lexicale entre certains textes et les performances du modèle.

## 1.3 Déroulement du projet

Le projet a été structuré selon les étapes suivantes :

1. Collecte des données.
2. Prétraitement et nettoyage des textes.
3. Analyse exploratoire et visualisation.
4. Entraînement des modèles.
5. Test, validation et sélection du meilleur modèle.
6. Déploiement dans une application Streamlit.

# Chapitre 2 Étude bibliographique

## 2.1 Traitement Automatique du Langage Naturel

Le NLP permet aux machines d'analyser et de comprendre le langage humain. Dans ce projet, il est utilisé pour transformer des textes bruts en représentations numériques exploitables par les algorithmes de Machine Learning.

## 2.2 Vectorisation TF-IDF

La méthode TF-IDF attribue un poids important aux termes spécifiques apparaissant fréquemment dans un document mais rarement dans l'ensemble du corpus. Cela permet de distinguer efficacement les termes médicaux des mots courants.

## 2.3 Algorithmes de classification

Deux algorithmes ont été étudiés :

- Régression Logistique, appréciée pour sa simplicité et ses performances sur les données textuelles.
- Random Forest, capable de modéliser des relations non linéaires.

# Chapitre 3 Vue conceptuelle

## 3.1 Collecte des données

Les données médicales ont été extraites de la base PubMed, tandis que les données non médicales proviennent de Kaggle. Le corpus final contient 23 379 documents équilibrés entre les deux classes.

## 3.2 Prétraitement des données

Le prétraitement comprend la suppression des caractères inutiles, la conversion en minuscules, l'élimination des stopwords et la vectorisation TF-IDF.

## 3.3 Analyse de la distribution des classes

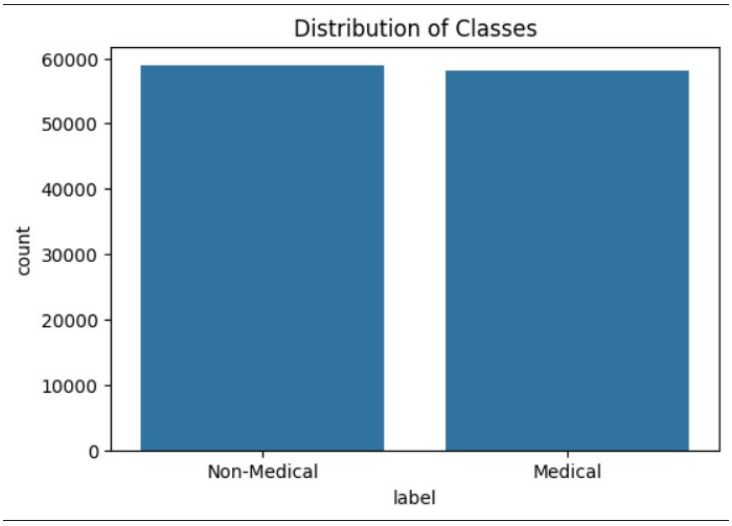


FIGURE 3.1 – Distribution des classes

# Chapitre 4 Implémentation et résultats

Ce chapitre présente la phase d'implémentation du système de classification ainsi que l'analyse détaillée des résultats obtenus. Il comprend une analyse exploratoire approfondie des données, l'entraînement des modèles de classification et l'évaluation comparative de leurs performances.

## 4.1 Analyse exploratoire des données

L'analyse exploratoire des données (EDA) constitue une étape fondamentale dans tout projet de Machine Learning. Elle permet de comprendre la structure du corpus textuel, d'identifier les caractéristiques distinctives entre les classes et de détecter d'éventuelles anomalies avant la phase de modélisation.

### 4.1.1 Distribution des longueurs des textes

La longueur des textes, mesurée en nombre de mots, représente un indicateur important de la complexité et de la richesse informationnelle des documents.

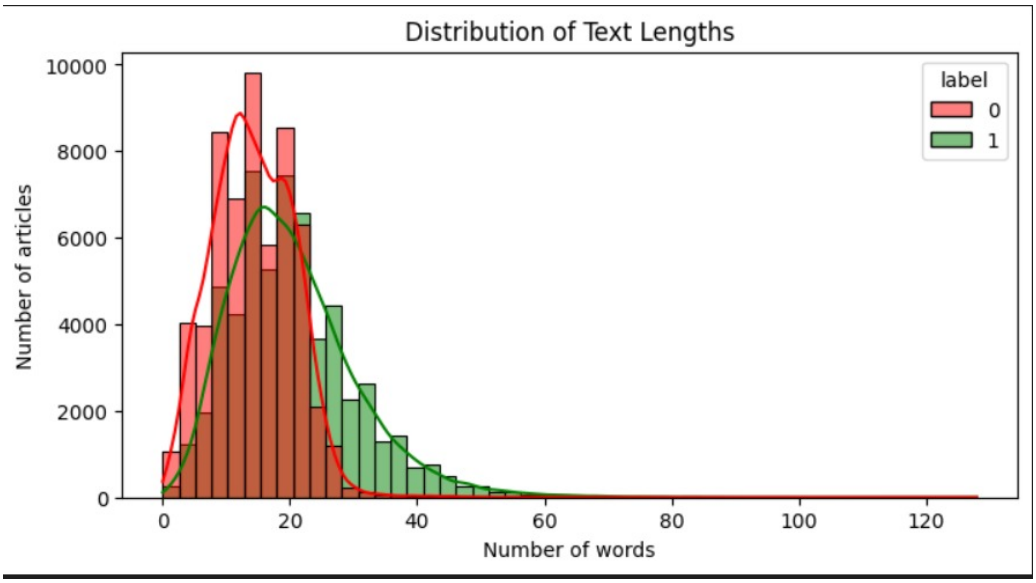


FIGURE 4.1 – Distribution des longueurs des textes

Cette figure montre que les articles médicaux ont tendance à être plus longs que les articles

non médicaux. Cela s'explique par la nature scientifique des textes médicaux, qui contiennent généralement des descriptions détaillées, des analyses méthodologiques et un vocabulaire technique spécialisé.

### 4.1.2 Analyse comparative par boxplot

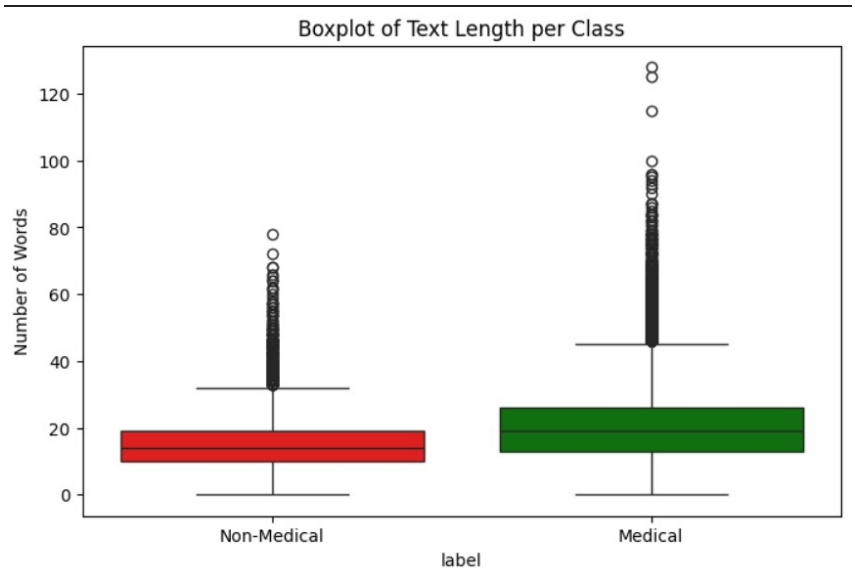


FIGURE 4.2 – Boxplot des longueurs des textes par classe

Le boxplot met en évidence une médiane plus élevée pour les textes médicaux ainsi qu'une dispersion plus importante. La présence de valeurs extrêmes indique l'existence d'articles médicaux très longs, tels que les revues scientifiques ou les essais cliniques.

### 4.1.3 Analyse lexicale et nuages de mots

L'analyse lexicale permet d'identifier les mots les plus représentatifs de chaque catégorie de textes.

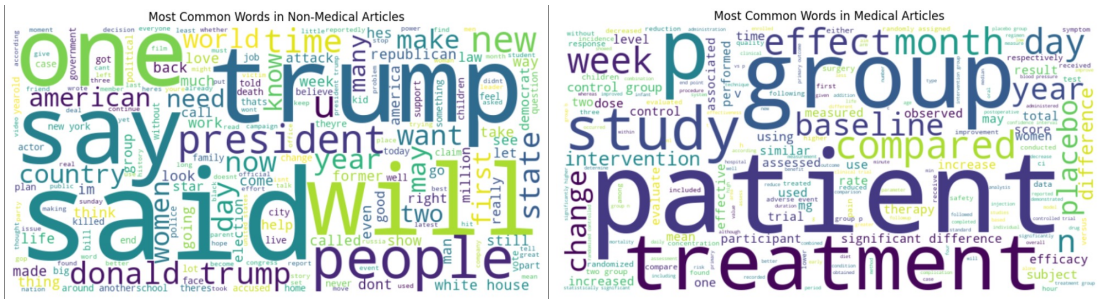


FIGURE 4.3 – Nuages de mots des articles médicaux et non médicaux

Les nuages de mots révèlent une dominance de termes scientifiques dans les articles médicaux tels que *patient*, *disease*, *clinical* et *treatment*. En revanche, les articles non médicaux

présentent un vocabulaire plus général lié à l'actualité, à la technologie et à la société.

### 4.1.4 Analyse des mots les plus fréquents

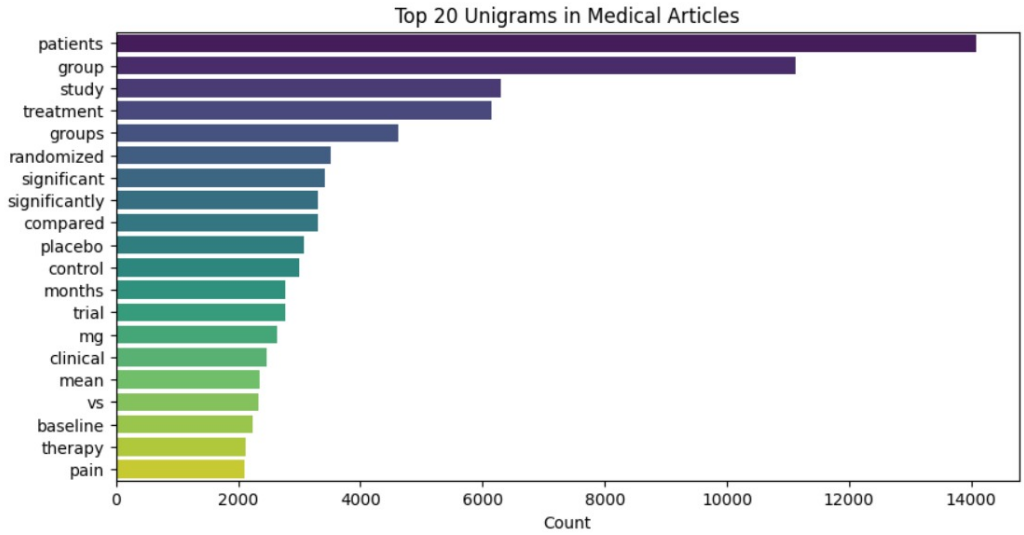


FIGURE 4.4 – Top 20 des unigrammes médicaux

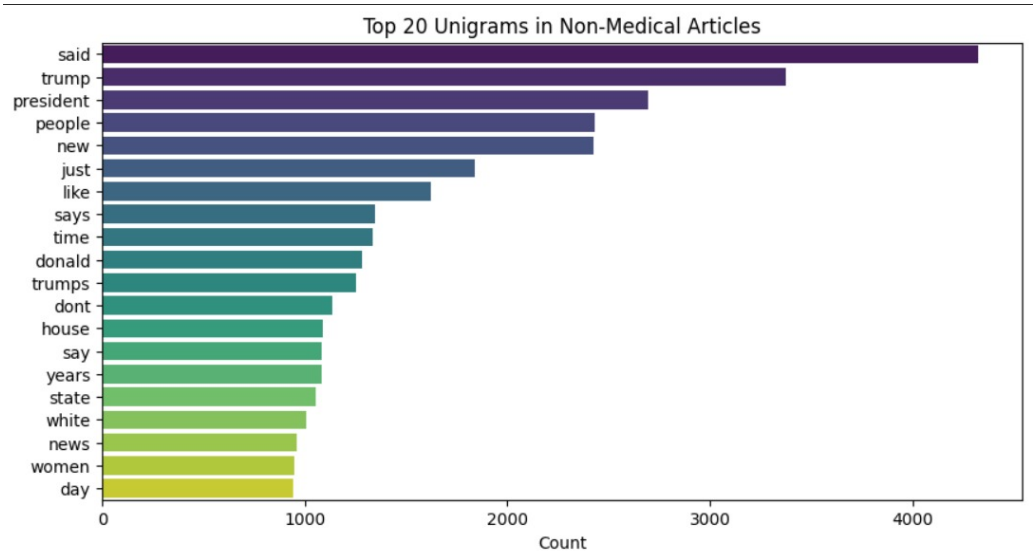


FIGURE 4.5 – Top 20 des unigrammes non médicaux

Ces résultats confirment l'existence d'un vocabulaire discriminant entre les deux classes, ce qui justifie l'utilisation de la vectorisation TF-IDF pour la phase de modélisation.

### 4.1.5 Longueur moyenne des textes par classe

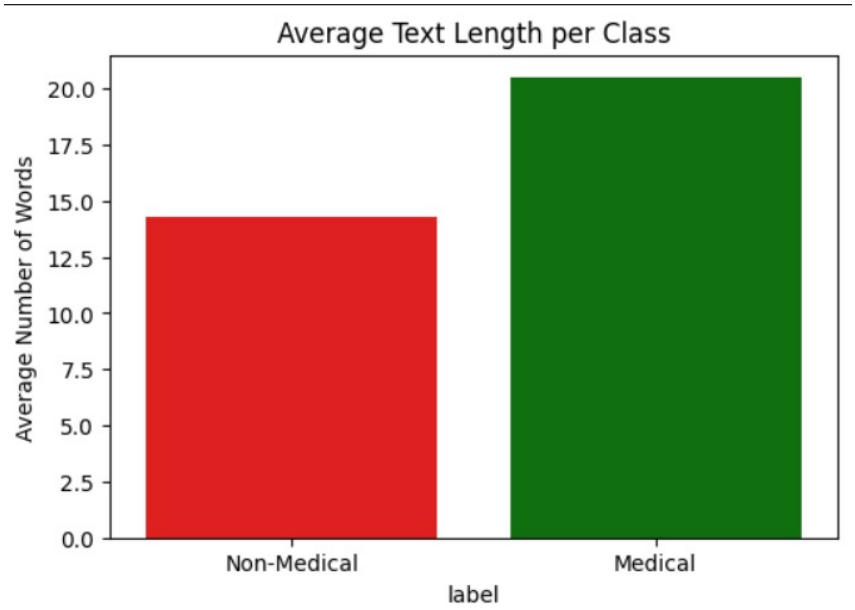


FIGURE 4.6 – Longueur moyenne des textes par classe

La comparaison des longueurs moyennes montre que les articles médicaux sont globalement plus longs que les articles non médicaux, ce qui constitue une caractéristique statistique supplémentaire différenciant les deux classes.

### 4.1.6 Distribution des classes

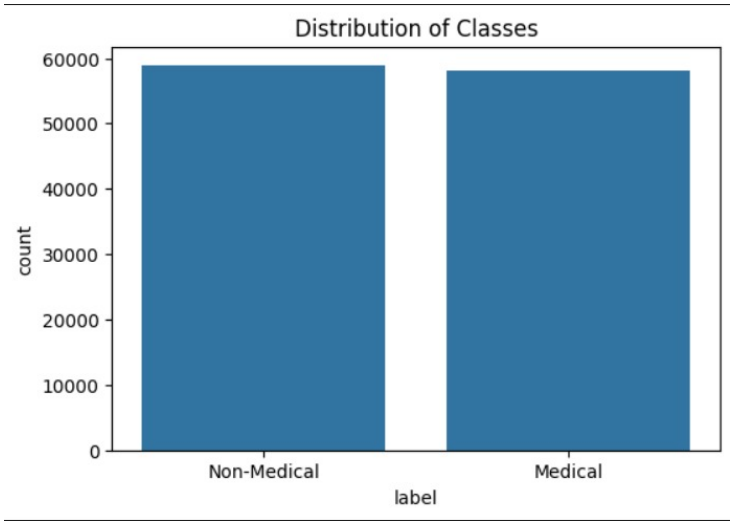


FIGURE 4.7 – Distribution des classes

La distribution des classes est relativement équilibrée, ce qui permet d'éviter les biais lors de l'entraînement des modèles et garantit une évaluation plus fiable des performances.

## 4.2 Modélisation et résultats

Après le prétraitement et la vectorisation des textes à l'aide de TF-IDF, les données ont été divisées en un ensemble d'entraînement (80%) et un ensemble de test (20%). Deux modèles de classification ont été implémentés : la Régression Logistique et le Random Forest.

### 4.2.1 Résultats de la Régression Logistique

```
Test Accuracy: 0.9846015655075068
              precision    recall  f1-score   support

           0       0.98      0.99      0.98     11744
           1       0.99      0.98      0.98     11635

    accuracy                           0.98     23379
   macro avg       0.98      0.98      0.98     23379
weighted avg       0.98      0.98      0.98     23379

[[11584   160]
 [  200 11435]]
```

FIGURE 4.8 – Résultats du modèle de Régression Logistique

Le modèle de Régression Logistique a obtenu une accuracy de **98,46%**, avec une précision et un rappel élevés pour les deux classes. Ces résultats montrent une excellente capacité de généralisation et une bonne séparation entre les articles médicaux et non médicaux.

### 4.2.2 Résultats du Random Forest

```
Accuracy: 0.9624449292099747
              precision    recall  f1-score   support

           0       0.95      0.97      0.96     11744
           1       0.97      0.95      0.96     11635

    accuracy                           0.96     23379
   macro avg       0.96      0.96      0.96     23379
weighted avg       0.96      0.96      0.96     23379

[[11440   304]
 [  574 11061]]
```

FIGURE 4.9 – Résultats du modèle Random Forest

Le modèle Random Forest présente une accuracy de **96,24%**. Bien que ses performances soient satisfaisantes, elles restent inférieures à celles de la Régression Logistique. Cela s'explique par la nature linéaire des données textuelles vectorisées par TF-IDF, plus adaptées aux modèles linéaires.

### 4.2.3 Comparaison des modèles

Les résultats globaux montrent que la Régression Logistique surpasse le Random Forest sur l'ensemble des métriques (accuracy, précision, rappel et F1-score). Ce modèle a donc été retenu comme solution finale pour le déploiement.

## 4.3 Application en temps réel

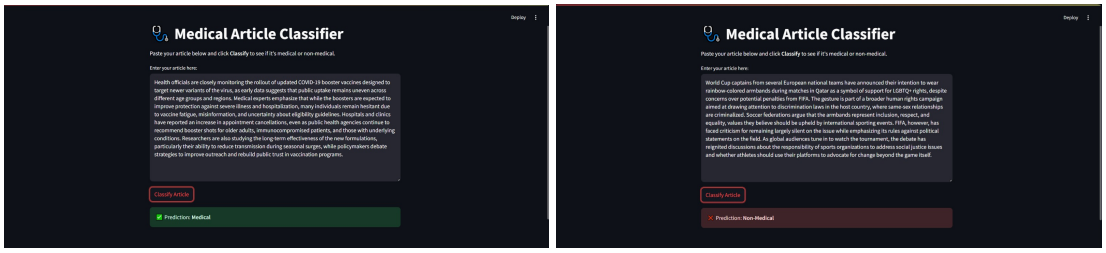


FIGURE 4.10 – Interface de l'application Streamlit

Une application web interactive a été développée à l'aide du framework Streamlit. Elle permet à l'utilisateur de saisir un texte libre et d'obtenir instantanément une prédiction indiquant si

le contenu est médical ou non médical. Cette application démontre la faisabilité d'un déploiement en temps réel du modèle de classification.

# Conclusion générale et perspectives

Ce projet démontre l'efficacité des techniques de NLP combinées au Machine Learning pour la classification de textes. Les résultats obtenus confirment que la Régression Logistique offre un excellent compromis entre performance et simplicité. À l'avenir, l'intégration de modèles plus avancés comme BERT permettra d'améliorer davantage la précision.

# Bibliographie


[1] PubMed. https ://pubmed.ncbi.nlm.nih.gov

[2] Kaggle Datasets. https ://www.kaggle.com

[3] Streamlit. https ://streamlit.io

[4] Salton, G. Introduction to Modern Information Retrieval.